

Ridge と Lasso の推定

B4 Y.Omori

Nagoya Institute of Technology
Takeuchi & Karasuyama Lab

May 6, 2019

- 1 はじめに
- 2 Ridge と Lasso の推定
- 3 計算機実験
- 4 まとめ

- 1 はじめに
正則化法
- 2 Ridge と Lasso の推定
- 3 計算機実験
- 4 まとめ

正則化法

複雑なモデルの推定において生じる過学習を防ぐ手法

本スライドでは、以下の 2 つの正則化法を紹介する

- Ridge
- Lasso

1 はじめに

2 Ridge と Lasso の推定

- 線形回帰モデル

- 正則最小 2 乗法

- Ridge とは

- Ridge の線形回帰モデル

- Ridge の推定量

- Lasso とは

- Lasso の計算手法

3 計算機実験

4 まとめ

次のような線形回帰モデルを考える.

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \epsilon_i \quad (1)$$

- i 番目 ($i = 1, 2, \dots, n$) のデータの目的変数: y_i
- 説明変数: $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})^\top \in \mathbb{R}^p$
- 誤差: $\epsilon_i \sim \mathcal{N}(0, \sigma^2)$
- 回帰係数: $\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_p)^\top \in \mathbb{R}^{p+1}$

線形回帰モデルに次の正則化項とハイパーパラメータを用いて記述する.

$$S_{\alpha}(\beta) = \sum_{i=1}^n \left(y_i - (\beta_0 + \sum_{j=1}^p \beta_j x_{ij}) \right)^2 + \alpha \sum_{j=1}^p |\beta_j|^q \quad (2)$$

- モデルの複雑度を設定するハイパーパラメータ: $\alpha \in \mathbb{R}^+$
- 正則化項: パラメータベクトルの長さの概念を一般化した L_q ノルム

式 (??) は第 2 項の q の値によって次のように呼ばれる.

1. $q = 1 \rightarrow$ Lasso
2. $q = 2 \rightarrow$ Ridge

Ridge

切片を除く回帰係数の2乗和を正則化項としてとることで、説明変数間の強い相関によって生じる回帰係数の推定値の不安定性を回避する手法

Ridge 推定量の求め方は次の式になる.

$$y_i = \beta_0^* + \beta_1 z_{i1} + \cdots + \beta_p z_{ip} + \epsilon_i \quad (3)$$

- j 番目の説明変数に関するデータの平均値: \bar{x}_j
- \bar{x}_j を中心化したデータ: $z_{ij} = x_{ij} - \bar{x}_j$
- $\beta_0^* = \beta_0 + \beta_1 \bar{x}_1 + \cdots + \beta_p \bar{x}_p$

式 (??) を行列形式にすると次のように変形できる.

$$\begin{aligned} \mathbf{y} &= \beta_0^* \mathbf{1} + Z\boldsymbol{\beta}_1 + \boldsymbol{\epsilon} \\ Z &= \begin{bmatrix} z_{11} & \cdots & z_{1p} \\ \vdots & z_{ij} & \vdots \\ z_{n1} & \cdots & z_{np} \end{bmatrix} \end{aligned} \tag{4}$$

- $\boldsymbol{\beta}_1 = (\beta_1, \beta_2, \dots, \beta_p)^\top \in \mathbb{R}^p$
- $\mathbf{1} = (1, 1, \dots, 1)^\top \in \mathbb{R}^n$

よって, Ridge の線形回帰モデルは次の式となる.

$$S_\alpha(\beta_0^*, \boldsymbol{\beta}_1) = (\mathbf{y} - \beta_0^* \mathbf{1} - Z\boldsymbol{\beta}_1)^\top (\mathbf{y} - \beta_0^* \mathbf{1} - Z\boldsymbol{\beta}_1) + \alpha \boldsymbol{\beta}_1^\top \boldsymbol{\beta}_1 \tag{5}$$

式 (??) を最小化することで、次のような切片と回帰係数ベクトルの推定量が与えられる.

$$\hat{\beta}_0^* = \bar{y} = \frac{\sum_{i=1}^n y_i}{n}, \quad \hat{\beta}_1 = (Z^\top Z + \alpha I_p)^{-1} Z^\top \mathbf{y} \quad (6)$$

式 (??) の結果から、式 (??) の切片は $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}_1 - \cdots - \hat{\beta}_p \bar{x}_p$ と推定される.

→ 中心化したデータから構成された計画行列 Z を用いれば、式 (??) の β_0^* を考えることなく、

$$S_\alpha(\beta_1) = (\mathbf{y} - Z\beta_1)^\top (\mathbf{y} - Z\beta_1) + \alpha \beta_1^\top \beta_1 \quad (7)$$

の最小化によって $\hat{\beta}_1$ を得られる.

Lasso

切片を除く回帰係数の絶対値の和を正則化項としてとることで、パラメータの一部は完全に 0 になることから、モデルの推定と変数選択を同時に実行できる手法

切片を除く回帰係数はデータを中心化することによって切片と切り離して推定できるため、次の式の最小化によって与えられる。

$$S_{\alpha}(\beta_1) = \sum_{i=1}^n \left(y_i - \sum_{j=1}^p \beta_j z_{ij} \right)^2 + \alpha \sum_{j=1}^p |\beta_j| \quad (8)$$

L_1 正則化項が微分不可能であるため解析的に β_1 を求めることはできない
→ 次のような計算手法が用いられる

- shooting アルゴリズム (Fu 1998)
- LARS (Efron et al. 2004)

また、ラグランジュの未定乗数法を適用すると、次の様な制約条件付きのベクトルの最小化と同等になる。

$$\min \sum_{i=1}^n \left(y_i - \sum_{j=1}^p \beta_j z_{ij} \right)^2 \quad \text{subject to} \quad \sum_{j=1}^p |\beta_j| \leq \eta \quad (9)$$

1 はじめに

2 Ridge と Lasso の推定

3 計算機実験

- 実験の設定

- 正則化の確認

- Lasso の変数選択の確認

- 決定係数の実験設定

- 決定係数の実験結果

4 まとめ

通常の最小 2 乗法, Ridge および Lasso を用いて回帰係数の推定を行った.

実験設定

- 目的変数: アメリカのボストン州の住宅価格
- 説明変数: 住宅価格に影響を与えていると思われる以下の 13 個
 - x_1 : 犯罪率
 - x_2 : 宅地の割合
 - x_3 : 非商用地
 - x_4 : チャールズ川流域か否か
 - x_5 : 窒素酸化物
 - x_6 : 部屋数
 - x_7 : 築年
 - x_8 : ビジネス地域への距離
 - x_9 : ハイウェイアクセス指数
 - x_{10} : 固定資産税
 - x_{11} : 生徒と教師の比率
 - x_{12} : 有色人種の割合
 - x_{13} : 低所得者の割合
- データ数: 506
- Ridge および Lasso のハイパーパラメータ: $\alpha \in \{0.01, 0.1, 1, 10, 100\}$

正則化の確認




Figure: 最小 2 乗法の推定値




Figure: Ridge の解パス




Figure: Lasso の解パス

- α が 0 に近いほど, Ridge と Lasso の各推定値は最小 2 乗法のそれに近い。
- α が大きくなるにつれて, Ridge も Lasso も全説明変数の推定値が 0 に向かって縮小している。
 - 特に, Lasso において $\alpha=100$ の場合は全ての回帰係数の値がほぼ 0 となっている。

→ α の大きさの違いによって正則化の強さが変化することを確認できる。

Lasso の変数選択の確認




Figure: Lasso の解パス

- 左図から変数選択の結果が確認できる。
 - $\alpha = 100$ において選択された変数
 - 固定資産税 (x_{10})
 - 有色人種の割合 (x_{12})
 - $\alpha = 10$ において選択された変数
 - x_{10} と x_{12}
 - 宅地の割合 (x_2)
 - 低所得者の割合 (x_{13})

決定係数の実験設定

推定手法の精度を比較するため、説明変数の数を 103 に増やしたもので同様の実験を行った。

実験設定

- 目的変数: アメリカのボストン州の住宅価格
- 説明変数: 住宅価格に影響を与えていると思われる以下の 103 個
- データ数: 506
- Ridge および Lasso のハイパーパラメータ: $\alpha \in \{0.01, 0.1, 1, 10, 100\}$

推定手法の精度の指標として決定係数 R^2 を用いた。

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2} \quad (10)$$

決定係数の実験結果




Figure: 決定係数

Table: 決定係数

α	0.01	0.1	1	10	100
train					
linear	0.95				
ridge	0.94	0.93	0.89	0.79	0.60
lasso	0.90	0.77	0.29	0.00	0.00
test					
linear	0.61				
ridge	0.70	0.77	0.75	0.64	0.42
lasso	0.77	0.63	0.21	0.00	0.00

- 訓練データ

- α が大きくなるにつれて、両方の決定係数が小さくなっている。

- テストデータ

- 適切な α を設定することで、両方において最小 2 乗法を上回る精度を出す。

- 1 はじめに
- 2 Ridge と Lasso の推定
- 3 計算機実験
- 4 **まとめ**

- Ridge と Lasso を中心に，正則化法や線形回帰モデルについて学ぶことができた．
- 数式だけでなく，Python のパッケージを用いた計算機実験による可視化を通して，自分の中でさらにイメージを具体化させることができた．
- 今後は，Lasso の計算に用いるアルゴリズムを理解して，パッケージを使わずに実装することが課題である．

1. 小西貞則, 『多変量解析入門』. 岩波書店, 2009.